

BÁO CÁO TIẾN ĐỘ DỰ ÁN NGHIÊN CỨU — BẢN NGẮN

Contagion: đo lan truyền prompt injection trong mạng LLM agent

Người báo cáo: _____ Lớp/Đơn vị: _____

Ngày báo cáo: _____

Bản ngắn 10 slide. Mỗi mục gồm [Nội dung slide] để chép lên slide chiếu, và [Lời nói] là văn nói đầy đủ. Muốn bản chi tiết (17 slide + phụ lục gồm câu hỏi hội đồng và từ điển thuật ngữ) thì dùng baocao_noidung.pdf.

Slide 1. Bối cảnh và câu hỏi nghiên cứu

Nội dung slide.

- LLM agent được triển khai như một *tổ chức*: planner → worker → reviewer → aggregator. Mỗi lần chuyển giao là một **ranh giới tin cậy**.
- Kẻ tấn công chen chỉ dẫn độc hại vào nguồn dữ liệu agent đọc; đầu ra của agent bị nhiễm trở thành đầu vào của agent sau.
- Benchmark hiện có (InjecAgent, AgentDojo) chỉ đo *một agent, một bước*.
- **Câu hỏi**: một agent bị nhiễm thì lan được bao xa, và cái gì quyết định nó sống sót qua mỗi lần chuyển giao?
- **Cách làm**: khung đo với *hai protocol độc lập*; 5 model / 5 nhà phát triển; 3 topology.

Lời nói. Kính thưa thầy/cô. Dự án của em nghiên cứu *lan truyền prompt injection trong mạng nhiều LLM agent*.

Các hệ thống LLM hiện nay không còn là một model đơn lẻ mà là một tổ chức: một agent lập kế hoạch, chia việc cho agent con, một agent kiểm tra, một agent tổng hợp. Dữ liệu truyền qua lại là văn bản tự do, nên mỗi lần chuyển giao là một ranh giới tin cậy — agent nhận không phân biệt được đâu là dữ liệu, đâu là mệnh lệnh. Kẻ tấn công khai thác đúng điểm đó: chỉ cần đặt chỉ dẫn độc hại vào một tài liệu hay một kết quả gọi công cụ mà agent sẽ đọc.

Các benchmark hiện có đều đo *một agent trong một bước*, nên không trả lời được câu hỏi em đặt ra: một khi đã lọt vào, nó lan được bao xa, và cái gì quyết định nó sống sót qua từng lần chuyển giao. Để trả lời, em xây một khung đo gồm hai protocol độc lập, chạy trên năm model thuộc năm nhà phát triển độc lập.

Slide 2. Phương pháp: hai protocol độc lập

Nội dung slide.

- **Protocol A — đo từng cạnh có kiểm soát**: ép đầu ra của agent nguồn thành “đã nhiễm” → đưa cho agent nhận → chấm. Cho $s_i = \Pr[C_i=1 \mid C_{i-1}=1]$.
- **Protocol B — chạy tự nhiên**: chạy cả mạng, đo tỉ lệ thành công đầu-cuối (ASR) và chỉ số lây nhiễm R_0 .
- **Vì sao hai?** Một cách đo thì khi hai con số lệch nhau, không phân biệt được “đo sai” với “hiệu sai hệ thống”.
- Chấm điểm **tắt định**, không dùng LLM làm giám khảo (tránh giám khảo cũng bị lây). 3 ngữ cảnh công việc hợp lệ xoay vòng.
- 5 model / 5 nhà phát triển độc lập: Llama 3.3 70B (Meta), DeepSeek V3.2 (DeepSeek), Claude Sonnet 4.5 (Anthropic), Nova Pro (Amazon), qwen2.5:7b (Alibaba, chạy local).

Lời nói. Điểm em muốn nhấn mạnh là em cố tình xây *hai* cách đo và giữ chúng tách biệt.

Cách thứ nhất: em không chờ mạng tự lan, mà chủ động *ép* đầu ra của agent trước thành nội dung đã bị nhiễm, đưa đúng nội dung đó cho agent sau, rồi chấm. Làm nhiều lần thì được xác suất có điều kiện: nếu agent trước đã nhiễm thì agent sau nhiễm với xác suất bao nhiêu. Cách thứ hai là để mạng chạy tự nhiên rồi đo tỉ lệ thành công đầu-cuối.

Lý do phải có cả hai: nếu chỉ có một cách đo, khi thấy hai con số không khớp, em không phân biệt được là do *em đo sai* hay do *hệ thống thực sự khác điều em tưởng*. Có hai cách độc lập thì mâu thuẫn giữa chúng trở thành một phát hiện.

Việc chấm “agent có bị nhiễm hay không” làm bằng công cụ tắt định, không dùng LLM làm giám khảo — vì trong bài toán lan truyền, giám khảo đọc chính nội dung cần chấm nên có thể bị ảnh hưởng. Em cũng dùng ba ngữ cảnh công việc hợp lệ khác nhau để kết quả không phụ thuộc vào một đề bài duy nhất.

Slide 3. Quy mô thực nghiệm: đã chạy những gì và bao nhiêu lần

Nội dung slide.

- **Tổng khối lượng:** 46 thư mục kết quả (25 có cấu trúc chuẩn); ≈ 9.070 lượt gọi model; 2.342 trial tự nhiên; 4,3 giờ thời gian máy ghi lại được.
- **5 model / 5 nhà phát triển · 2 protocol độc lập · 3 topology · 3 defense · 3 kiểu biến hình tấn công.**
- **Cấu hình từng loại thí nghiệm:**

Loại thí nghiệm	Số lần chạy
Ô chuẩn (mọi model)	chuỗi $n = 4$: 40 trial tự nhiên + 30 trial/cạnh
Đường cong chiều sâu	60 trial tự nhiên; 30/cạnh (qwen 25); chuỗi $n = 15$ (Llama), $n = 8$ (DeepSeek), $n = 7$ (qwen)
Mô hình có vòng	40 trial $\times$ 5 vòng $\times$ 3 agent
Utility (công việc hợp lệ)	20 cặp sạch/bị tấn công cho mỗi defense
Độ nhảy (seed $\times$ temp)	8 seed $\times$ 20 trial/cạnh ở temp 0,7
Biến hình $\times$ defense	6 ô $\times$ 30 mẫu/ô
Topology	3 topology $\times$ $n = 7$: 40 trial tự nhiên + 30/cạnh

- Cách đếm: lượt gọi là **ước lượng cận dưới** tính từ cấu hình (trial tự nhiên $\times$ số agent + trial/cạnh $\times$ số cạnh), *chưa* tính các lần thử lại khi ép đầu ra bị nhiễm và các lần chạy hỏng.

Lời nói. Thầy/cô thường hỏi khối lượng thực nghiệm, nên em chuẩn bị riêng một slide cho việc này.

Tính đến nay em đã chạy khoảng *chín nghìn lượt gọi model*, trên *hai nghìn ba trăm trial tự nhiên*, trải qua bốn mươi sáu thư mục kết quả. Con số chín nghìn là *ước lượng cận dưới*: em đếm theo công thức từ cấu hình của từng thí nghiệm chứ không đếm từng lần gọi, và chưa tính các lần thử lại khi phải ép đầu ra thành nội dung bị nhiễm. Em nói rõ điều này để không ai hiểu nhầm đó là con số đo trực tiếp.

Về cấu hình cụ thể. Mỗi ô chuẩn — tức là mỗi model, mỗi topology — chạy bốn mươi lần tự nhiên, cộng ba mươi lần cho *mỗi cạnh* theo giao thức có kiểm soát. Thí nghiệm đường cong chiều sâu chạy sáu mươi lần tự nhiên trên chuỗi dài, tới mười lăm agent với Llama và bảy đến tám agent với hai model còn lại. Thí nghiệm mô hình có vòng chạy bốn mươi lần, mỗi lần năm vòng. Phần đo ảnh hưởng lên công việc hợp lệ chạy hai mươi cặp sạch và bị tấn công cho mỗi cơ chế phòng thủ. Phần độ nhảy chạy tám seed, mỗi seed hai mươi lần mỗi cạnh. Bảng biến hình tấn công có sáu ô, mỗi ô ba mươi mẫu.

Có hai điểm em muốn nói thêm về con số này. Thứ nhất, thời gian máy ghi lại được là bốn phẩy ba giờ, nhưng đây cũng là cận dưới, vì hai họ script — đường cong chiều sâu và mô hình có vòng — không ghi lại thời gian chạy. Thứ hai, điều quan trọng không phải là con số chín nghìn, mà là *mỗi ô đều có khoảng tin cậy và đều công bố độ lệch nhỏ nhất phát hiện được*. Chạy nhiều mà không biết mình phát hiện được gì thì con số lớn cũng không có ý nghĩa.

Slide 4. Kết quả 1 và 2: “giả định Markov” là đẳng thức, và nó *thất bại*

Nội dung slide.

- Trong chuỗi: $C_i=1 \Rightarrow C_{i-1}=1 \Rightarrow \text{ASR} = \prod_i s_i^{\text{nat}}$ là **đẳng thức**, không phải giả định (kiểm: chuỗi 4 agent 0,850 = 0,850; chuỗi 7 agent 0,450 = 0,450).
- Vậy câu hỏi thật là: con số đo *cách ly* có bằng con số *trong chuỗi*? Câu trả lời: **tuỳ model**.
 - DeepSeek: khớp tới 2,2% $\Rightarrow$ chuyển được.
 - Llama: cạnh giữa cách ly 0,233 nhưng trong chuỗi 0,875 $\Rightarrow$ **lệch 3,75 lần**.
- **Sai số lớn dần theo độ sâu** — đo trên chuỗi dài, 3 model:

Model	Chuỗi	Sai số	ρ	Độc (%/hop)
qwen2.5:7b	n=7	31% $\rightarrow$ 89%	+1,00	+11,8
Llama 3.3 70B	n=15	0% $\rightarrow$ 92%	+0,77	+6,8
DeepSeek V3.2	n=8	7%–35%	–0,07	+0,1

- $\Rightarrow$ **độ độc đường cong là phép chẩn đoán**: một chuỗi dài, một lần chạy, biết ngay model đó có cộng dồn được hay không.

Lời nói. Đây là kết quả trung tâm. Trước hết, một kết quả lý thuyết: trong chuỗi, để agent thứ ba bị nhiễm thì agent thứ hai phải đã nhiễm, vì chính đầu ra của agent thứ hai mới lây sang agent thứ ba. Hệ quả là tỉ

lệ thành công đầu-cuối *đúng bằng* tích các xác suất có điều kiện — một đẳng thức, không phải giả định cần kiểm định. Em kiểm bằng số đo thật: chuỗi bốn agent cho 0,850 và tích cũng 0,850; chuỗi bảy agent cho 0,450 và tích cũng 0,450.

Vậy câu hỏi “Markov có đúng không” là câu hỏi đặt sai. Câu hỏi đúng là: con số đo *cách ly* — đo riêng lẻ từng cạnh — có bằng con số khi mạng chạy thật không. Câu trả lời là *tùy model*. Với DeepSeek thì khớp tới hai phần trăm. Với Llama thì ngược lại: một cạnh ở giữa đo cách ly cho 0,233 nhưng trong chuỗi thật là 0,875 — đo cách ly đánh giá thấp gần bốn lần.

Đáng chú ý hơn là *quy luật* của sai số. Em chạy một chuỗi dài, mỗi nút là một mức độ sâu, rồi so tích các con số cách ly với xác suất nhiễu thật. Với qwen, sai số tăng đơn điệu từng bước, tương quan hạng đúng bằng +1. Với Llama, tương quan +0,77, lên tới 92%. Với DeepSeek thì không có xu hướng nào.

Ý nghĩa thực tiễn: độ dốc của đường cong tự nó là phép chẩn đoán. Chỉ cần một chuỗi dài, một lần chạy, nhìn độ dốc là biết có nên tin vào việc nhân các con số đo cách ly hay không. Một chi tiết về trung thực: bốn điểm cuối của Llama không xác định được vì chuỗi đã chết hẳn, nên em *loại* chứ không gán cho chúng sai số 100% cho đẹp hình.

Slide 5. Cơ chế: hình thức của thông điệp quyết định

Nội dung slide.

- Cùng mục tiêu, cùng agent nhận, cùng cách chăm, cùng phân công — chỉ đổi cách trình bày:

Cách trình bày	Xác suất sống sót
Một câu khẳng định trần	0,067
Nhúng trong một sản phẩm công việc	0,967

- Chênh **14 lần** chỉ vì cách đóng gói.
- Đây là lời giải thích cho kết quả trước: artefact “chuẩn hoá” dùng khi đo cách ly *không đại diện* cho thông điệp thật trong mạng.
- Tự kiểm tra lại: phát lại nội dung bắt được khớp **2/3** cạnh — báo cáo đúng 2/3, không làm tròn thành “khớp hoàn toàn”.

Lời nói. Kết quả trước nói rằng phép đo cách ly sai. Câu hỏi tiếp là sai vì cái gì. Câu trả lời: vì *hình thức* của thông điệp.

Em làm một thí nghiệm đối chứng rất gọn: giữ nguyên mọi thứ — cùng mục tiêu, cùng các agent nhận, cùng cách chăm, cùng phân công — chỉ đổi cách trình bày. Nếu nội dung độc hại đến dưới dạng một câu khẳng định trần, tỉ lệ sống sót là 0,067, tức gần như bị chặn hết. Nếu nó được nhúng vào trong một sản phẩm công việc thật, tỉ lệ sống sót là 0,967. Chênh nhau mười bốn lần, chỉ vì cách đóng gói.

Điều này giải thích vì sao phép đo cách ly lệch: khi đo cách ly, em buộc phải dùng một artefact “chuẩn hoá” để đưa cho agent nhận, và artefact đó không đại diện cho thông điệp thật trong mạng.

Em cũng tự kiểm tra lại chính mình bằng cách phát lại nội dung đã bắt được trong chuỗi thật. Kết quả là hai trên ba cạnh tái hiện được, và em báo cáo đúng hai trên ba.

Slide 6. Kết quả 3: tiêu chí ngưỡng dịch tễ vô hiệu với mạng agent

Nội dung slide.

- Tiêu chí quen thuộc: “ $R_0 < 1$ thì dịch tắt, hệ an toàn”.
- **Định lý:** ma trận lây nhiễm của *mọi* mạng không có vòng, sắp theo topology, là **tam giác chặt** $\Rightarrow$ mọi giá trị riêng bằng 0 $\Rightarrow \rho(M) = 0$ **luôn luôn**, bất kể cạnh mạnh cỡ nào.
- Nghĩa là tiêu chí được thoả mãn *tâm thường*: không phân biệt được hệ an toàn với hệ nguy hiểm.
- Bằng chứng thực nghiệm:
 - chuỗi 7 agent: $R_0 = 0,821 < 1$ nhưng $ASR = 0,450$
 - hình sao: $R_0 = 0,420 < 1$ nhưng $ASR = 0,725$
- **Độ lan tới** và **khả năng tái lây** là hai rủi ro khác nhau.

Lời nói. Kết quả thứ ba là phản biện một công cụ đang được dùng rộng rãi. Trong mạng lưới nói chung, người ta hay dùng tiêu chí: nếu chỉ số lây nhiễm nhỏ hơn một thì dịch sẽ tắt.

Em chứng minh rằng với mạng agent dạng feed-forward — mạng không có vòng, mọi agent chỉ chuyển tiếp về phía trước — thì tiêu chí này *luôn luôn* được thoả mãn một cách tầm thường. Lý do rất gọn: ma trận mô tả “một agent lây cho bao nhiêu agent”, khi sắp theo thứ tự truyền, luôn có dạng tam giác; mà ma trận tam giác thì toàn bộ giá trị riêng bằng không. Không phụ thuộc cạnh mạnh hay yếu. Tức là tiêu chí đó luôn báo “an toàn”.

Thực nghiệm xác nhận: chuỗi bảy agent có chỉ số lây nhiễm 0,821, nhỏ hơn một, nhưng vẫn có 45 phần trăm số lần tấn công thành công đầu-cuối. Hình sao còn rõ hơn: chỉ số 0,420 mà tỉ lệ thành công tới 72,5 phần trăm. Nghĩa là “đi được tới đích” và “tái lây được tiếp” là hai rủi ro khác nhau.

Slide 7. Kết quả 3 (tiếp): có vòng lặp thì tiêu chí có hiệu lực — và thành quy tắc thiết kế

Nội dung slide.

- Mô hình thật: manager giao việc cho w worker, worker **báo cáo ngược lại**.
- Công thức (kiểm bằng số tới $4,4 \times 10^{-16}$ trên 320 cấu hình):

$$\rho(M) = \sqrt{\sum_j a_j c_j} \quad \text{với mọi } w, \quad \text{vượt ngưỡng} \iff \sum_j a_j c_j > 1.$$

- Không có báo cáo ngược ($c_j=0$) $\Rightarrow \rho = 0$ bất kể cạnh mạnh cỡ nào.
- Đối xứng ($a_j=c_j=s$): $w s^2 > 1$ — ở $s=0,5$ cần **5** worker, 0,7 cần **3**, 0,9 cần **2**.
 - Hai dự đoán ngược nhau, cả hai đều đúng:

Model	$\sum_j a_j c_j$	ρ	Dự đoán $\rightarrow$ Đo được
Llama	1,800	1,342	bền $\rightarrow$ manager 0,725, vòng 5 còn 0,700 ✓
qwen	0,578	0,760	yếu dần $\rightarrow$ manager 0,775 $\rightarrow$ 0,650 ✓

- Giới hạn đã ghi trong bài: mới 5 vòng — đủ phân biệt “yếu dần” với “bão hoà”, *chưa* đủ chứng minh tất hần.

Lời nói. Nhưng tiêu chí ngưỡng không phải lúc nào cũng vô nghĩa — nó chỉ vô nghĩa khi mạng không có vòng. Mà mạng agent thật thì *có* vòng: mô hình rất phổ biến là một manager giao việc cho các worker, rồi worker báo cáo kết quả ngược trở lại. Chính các cạnh báo cáo ngược đó tạo thành vòng.

Em tính được công thức bán kính phổ cho mô hình này: căn bậc hai của tổng, qua từng worker, của tích “xác suất lây xuống nhân xác suất báo cáo ngược lên”. Em kiểm công thức bằng số trên hơn ba trăm cấu hình ngẫu nhiên, sai số lớn nhất là bốn phần mười mũ mười sáu — tức là một đẳng thức, không phải xấp xỉ.

Từ đó ra một *quy tắc thiết kế*: hệ bắt đầu tự duy trì lây nhiễm khi tổng đó lớn hơn một. Trường hợp đối xứng thì điều kiện là w nhân s bình phương lớn hơn một. Cụ thể: xác suất sống sót mỗi chiều là 0,5 thì cần năm worker mới vượt ngưỡng; 0,7 thì cần ba; 0,9 thì chỉ cần hai.

Điểm em thấy quan trọng nhất: công thức này *dám* đưa ra hai dự đoán *ngược nhau* trên hai model em đã đo, và em đã chạy cả hai. Với Llama, tổng bằng 1,8, dự đoán vượt ngưỡng — và thực tế manager bị tái nhiễm bởi chính báo cáo của worker mình với xác suất 0,725, tới vòng năm vẫn còn 0,700, tức hệ không tắt. Với qwen, tổng chỉ 0,578, dự đoán yếu dần — và thực tế manager từ 0,775 giảm còn 0,650 ở vòng năm, worker dừng lại chứ không bão hoà.

Em xin nói rõ giới hạn: mới chạy năm vòng, đủ để phân biệt “yếu dần” với “bão hoà” nhưng chưa đủ để khẳng định tất hần, nên trong bài em không dùng chữ “tất hần”.

Slide 8. Kết quả 4: đánh giá phòng thủ cần baseline “không phòng thủ”

Nội dung slide.

- Cùng defense, cùng kiểu tấn công, cùng code chấm điểm, chỉ đổi model:

- Claude: không phòng thủ đã chỉ 0,10; bật redaction còn 0,00 $\Rightarrow$ “trông hoàn hảo” nhưng chỉ có 10% để bảo vệ.
- DeepSeek: không phòng thủ 1,00; bật redaction còn 0,00 $\Rightarrow$ defense thật sự làm hết việc.
- **Kết luận:** thiếu baseline “không phòng thủ” thì *không xác định được* hiệu quả của một defense.
- Kèm theo: biến hình tấn công (tách chuỗi, chèn khoảng trắng) phá được redaction.
- Phải báo cáo *cấp* (ASR, mức mất công việc hợp lệ): trên DeepSeek, paraphrase **không giảm** ASR mà còn làm mất thêm công việc hợp lệ — tệ hơn cả không làm gì.

Lời nói. Kết quả thứ tư là về *cách đánh giá*. Em dùng cùng một cơ chế phòng thủ, cùng kiểu tấn công, cùng đoạn code chấm điểm, chỉ đổi model.

Trên Claude, khi *không* bật phòng thủ, tỉ lệ nhiễm đã chỉ là 0,10; bật redaction lên thì còn 0,00. Nhìn con số cuối thì có vẻ hoàn hảo, nhưng thực ra nó chỉ có mười phần trăm để bảo vệ — phần còn lại là model vốn đã kháng tốt. Trên DeepSeek, cùng phép so sánh lại có ý nghĩa khác hẳn: không phòng thủ là 1,00, bật lên còn 0,00.

Nên khuyến nghị phương pháp là: báo cáo đánh giá phòng thủ mà không kèm con số baseline khi không phòng thủ thì người đọc *không thể* biết phòng thủ đó có thật sự làm việc hay không. Em gọi đây là hiệu ứng sần.

Thêm một điểm nữa: phải báo cáo cả *công việc hợp lệ còn làm được bao nhiêu*. Trên DeepSeek, cơ chế viết lại ngữ nghĩa paraphrase không giảm được lan truyền chút nào mà còn làm mất thêm công việc hợp lệ — tệ hơn cả việc không làm gì. Nếu chỉ báo cáo mỗi tỉ lệ tấn công thì nó trông “trung tính”; chỉ khi báo cáo cặp hai con số mới thấy vấn đề.

Slide 9. Kết quả phụ: vai trò agent và năng lực model

Nội dung slide.

- Cùng model, cùng kiểu tấn công: xác suất sống sót chênh 6,5 **lần** giữa các vai trò (worker 0,133 so với reviewer 0,867).
- “Dễ bị lây” **không** đi theo “model mạnh hơn”:

Model	ASR	$\bar{s}$
Llama 3.3 70B	0,800	0,722
DeepSeek V3.2	0,475	0,933
qwen2.5:7b	0,300	0,611
Nova Pro	0,075	0,178
Claude Sonnet 4.5	0,000	0,211

- **Topology** ở cùng 7 agent, cùng $\bar{s} \approx 0,76$: ASR 0,450 / 0,725 / 0,800 cho chain / star / tree.
- **Đặt phòng thủ ở đâu:** trên mạng không vòng, chỉ agent trên đường tới mục tiêu mới có ý nghĩa, và mọi agent trên đường đó *hiệu quả như nhau* $\Rightarrow$ bài toán *cấu trúc*, không phải thống kê.

Lời nói. Hai kết quả phụ, nhưng theo em là quan trọng cho người thiết kế hệ thống.

Thứ nhất, xác suất lây không phải thuộc tính của model mà là thuộc tính của *vị trí* agent trong quy trình. Cùng một model và cùng kiểu tấn công, agent ở vai trò worker có xác suất bị lây 0,133, còn reviewer là 0,867 — chênh sáu lần rưỡi.

Thứ hai, trực giác “model mạnh hơn thì an toàn hơn” không đúng. Llama 3.3 70B có tỉ lệ tấn công thành công 0,800, cao hơn DeepSeek 0,475, cao hơn qwen 0,300, cao hơn Nova Pro 0,075, và Claude gần như bằng không. Đây không phải thứ tự năng lực. Nên phải đo trên đúng model mình dùng, không suy ra từ bảng xếp hạng. Topology cũng quyết định: ba mạng bảy agent có cùng xác suất lây trung bình nhưng cho tỉ lệ thành công khác hẳn nhau.

Cuối cùng, từ định lý ở kết quả ba, em rút ra câu trả lời cho câu hỏi “đặt phòng thủ ở đâu”: trên mạng không có vòng, chỉ agent nằm trên đường từ điểm xâm nhập tới mục tiêu mới đáng quan tâm, và trong số đó mọi agent đều hiệu quả như nhau. Nghĩa là đây là bài toán về cấu trúc đồ thị và chi phí triển khai, không phải bài toán cần số liệu thống kê.

Slide 10. Trung thực phương pháp: một phát hiện của chính em đã bị rút lại

Nội dung slide.

- Ban đầu: trên DeepSeek, kiểm định bác bỏ giả thuyết Markov với $p = 0,0030$ — tưởng là phát hiện lớn.
- Nguyên nhân thật: protocol khi đó *giữ cố định* artefact đã nhiễm và dùng lại cho mọi trial $\Rightarrow$ các trial phụ thuộc nhau, độ lệch bị phóng đại.
- Sửa: thêm chế độ `--fresh-artifact` (mỗi trial rút artefact mới) $\Rightarrow$ chạy lại: $p = 0,630$, *không* bác bỏ được gì.
- Giữ cả cái sai và cách sửa trong bài: với nghiên cứu đo lường, **cách đo là một phần của kết quả**.
- Ngược lại, bất thường của Llama *đứng vững* qua cả hai chế độ artefact.

Lời nói. Phần này em dành riêng để nói về một sai sót của chính mình, vì em nghĩ nó là một phần quan trọng của tiền độ.

Giai đoạn đầu, em chạy kiểm định thống kê và thấy trên DeepSeek giả thuyết Markov bị bác bỏ với p bằng 0,003 — một kết quả rất mạnh, đủ để viết thành đóng góp chính. Nhưng khi kiểm tra lại quy trình đo, em phát hiện protocol khi đó *giữ cố định* một artefact đã bị nhiễm và dùng lại cho mọi trial. Cách làm đó khiến các trial không còn độc lập và làm độ lệch bị phóng đại.

Em sửa bằng cách rút artefact mới cho từng trial rồi chạy lại: p bằng 0,630, hoàn toàn không bác bỏ được gì. Kết quả cũ là artefact của thiết kế đo.

Em giữ cả hai trong bài — cả cái sai và cách sửa — vì trong nghiên cứu đo lường, cách đo là một phần của kết quả. Để công bằng, em cũng kiểm ngược: kết quả bất thường của Llama thì đứng vững qua cả hai chế độ, tức đó là bất thường thật.

Slide 11. Sản phẩm, hạn chế, kế hoạch

Nội dung slide.

- **Sản phẩm:** bản thảo bài báo định dạng AAMAS 2027 — **8 trang nội dung** + 1 trang tài liệu tham khảo (đúng giới hạn); 8 bảng + 2 hình; mọi số sinh tự động từ file kết quả, *không nhập tay*.
- Kèm theo: tài liệu tái lập (mỗi bảng gắn với câu lệnh sinh ra nó) và script đối chiếu từng con số trong bài với kết quả gốc.
- **Hạn chế (đã ghi rõ trong bài):** utility đo bằng proxy; cỡ mẫu $n = 30\text{--}40$ (chỉ phát hiện được lệch $> 0,26$); chưa có topology lưới/tranh luận; mô hình có vòng mới có 1 instance; transportability mới chứng minh *tồn tại* thất bại; chưa hiệu chỉnh đa so sánh.
- **Kế hoạch:** mở rộng topology (lưới, tranh luận); nhiệm vụ có đáp án kiểm chứng được để đo utility thật; chạy lại các ô quan trọng ở cỡ mẫu lớn hơn.

Lời nói. Về sản phẩm, hiện em có một bản thảo bài báo hoàn chỉnh theo định dạng hội nghị AAMAS 2027, dài đúng tám trang nội dung cộng một trang tài liệu tham khảo. Nguyên tắc em đặt ra từ đầu là *không có con số nào nhập tay*: mọi bảng hình đều sinh tự động từ file kết quả, và em có thêm một script đối chiếu từng con số trong bài với kết quả gốc — nó đã phát hiện và giúp em sửa hai chỗ ghi thiếu chính xác.

Về hạn chế, em xin nói thẳng. Đại lượng đo mức ảnh hưởng lên công việc hợp lệ hiện là đại lượng thay thế, chưa phải độ đúng thật. Cỡ mẫu phần lớn là ba mươi đến bốn mươi lần chạy, ở cỡ đó chỉ phát hiện được lệch lớn hơn 0,26, và em công bố con số này trong bài chứ không giấu. Em chưa có topology mạng lưới và mạng tranh luận; mô hình có vòng mới có một instance; và kết quả về tính chuyển được mới chứng minh sự *tồn tại* của thất bại, chưa ước lượng được tần suất.

Kế hoạch tiếp theo là mở rộng độ phủ topology, đặc biệt là mạng có đường song song vì đó là nơi bài toán đặt phòng thủ trở thành bài toán tối ưu thật sự; và xây một họ nhiệm vụ có đáp án kiểm chứng được để đo mức ảnh hưởng lên công việc một cách chính xác.

Slide 12. Kết luận

Nội dung slide.

- Lan truyền prompt injection trong mạng agent là hiện tượng **đa tác nhân**: tầm với của một vụ nhiễm là thuộc tính của *đồ thị, vai trò và thông điệp*.
- **Ba thông điệp**:
 1. Con số ASR của benchmark một-agent **không** dùng được như tham số để nhân lên thành dự đoán cho pipeline; sai số *tăng theo độ dài pipeline* (và độ dốc đó là phép chặn đoán).
 2. “ $R_0 < 1$ là an toàn” **không** dùng được cho mạng không vòng; khi có vòng thì tiêu chí *có* hiệu lực, và trở thành quy tắc thiết kế ($\sum_j a_j c_j > 1$) đã được kiểm hai chiều trên hai model.
 3. Đánh giá defense mà thiếu baseline “không phòng thủ” thì **không xác định được** hiệu quả.
- Sản phẩm: khung đo tái lập được + bản thảo 8 trang + toàn bộ dữ liệu thô, kể cả một phát hiện sai của chính nhóm đã được rút lại.

Lời nói. Em xin kết luận. Điểm cốt lõi: lan truyền prompt injection trong mạng agent là hiện tượng đa tác nhân, và tầm với của một vụ nhiễm là thuộc tính của đồ thị, của vai trò agent và của hình thức thông điệp — không phải thuộc tính của một agent đơn lẻ.

Ba thông điệp em muốn mang về. Một: con số tỉ lệ tấn công thành công mà các benchmark đo trên một agent không dùng được như tham số để nhân lên thành dự đoán cho cả pipeline, và mức sai lệch tăng theo độ dài pipeline — hơn nữa, độ dốc của đường cong đó tự nó là phép chặn đoán. Hai: tiêu chí ngưỡng “chỉ số lây nhiễm nhỏ hơn một thì an toàn” không dùng được cho mạng không có vòng, nhưng khi mạng có vòng thì tiêu chí trở nên có hiệu lực và trở thành một quy tắc thiết kế, đã được kiểm hai chiều. Ba: đánh giá một cơ chế phòng thủ mà thiếu con số baseline khi không phòng thủ thì không thể xác định được hiệu quả.

Sản phẩm bàn giao gồm khung đo tái lập được, bản thảo tám trang, và toàn bộ dữ liệu thô — trong đó em giữ lại cả một phát hiện sai của chính mình và cách sửa nó.

Em xin hết phần trình bày và sẵn sàng nhận câu hỏi của thầy/cô.