

Contagion: đo lan truyền prompt injection trong mạng LLM agent

Báo cáo tiến độ — bản ngắn

Người báo cáo: _____

Lớp/Đơn vị: _____

- LLM agent triển khai như một **tổ chức**: planner → worker → reviewer → aggregator. Mỗi lần chuyển giao là một **ranh giới tin cậy**.
- Kẻ tấn công chèn chỉ dẫn độc hại vào nguồn dữ liệu agent đọc; đầu ra của agent bị nhiễm thành đầu vào của agent sau.
- Benchmark hiện có chỉ đo **một agent, một bước**.
- **Câu hỏi**: một agent bị nhiễm thì lan được bao xa, và cái gì quyết định nó sống sót qua mỗi lần chuyển giao?
- **Cách làm**: khung đo *hai protocol độc lập*; 5 model / 5 nhà phát triển; 3 topology.

A — đo từng cạnh có kiểm soát

ép đầu ra agent nguồn thành “đã nhiễm” $\rightarrow$ đưa cho agent nhận $\rightarrow$ chấm
 $\Rightarrow s_i = \Pr[C_i=1 \mid C_{i-1}=1]$.

B — chạy tự nhiên

Chạy cả mạng $\Rightarrow$ tỉ lệ thành công đầu-cuối (ASR) và chỉ số lây nhiễm R_0 .

- **Vì sao hai?** Một cách đo thì khi hai con số lệch nhau, không phân biệt được “*đo sai*” với “*hiểu sai hệ thống*”.
- Chấm **tất định**, *không* dùng LLM làm giám khảo; 3 ngữ cảnh công việc hợp lệ xoay vòng.

Quy mô thực nghiệm: đã chạy bao nhiêu?

- $\approx$ **9.070 lượt gọi model** (cận dưới) · **2.342 trial** tự nhiên · 46 thư mục kết quả · **4,3 giờ** máy (cận dưới)
- **5 model / 5 nhà phát triển** · **2 protocol** · **3 topology** · **3 defense** · **3 kiểu biến hình**

Loại thí nghiệm	Số lần chạy
Ô chuẩn (mọi model)	chuỗi $n=4$: 40 trial tự nhiên + 30 trial/cạnh
Đường cong chiều sâu	60 trial; 30/cạnh; $n=15$ / $n=8$ / $n=7$
Mô hình có vòng	40 trial $\times$ 5 vòng $\times$ 3 agent
Utility (công việc hợp lệ)	20 cặp sạch/tấn công cho mỗi defense
Độ nhảy (seed $\times$ temp)	8 seed $\times$ 20 trial/cạnh
Biến hình $\times$ defense	6 ô $\times$ 30 mẫu/ô
Topology	3 topology $\times$ $n=7$

- Lượt gọi là **ước lượng cận dưới** — chưa tính lần thử lại và lần chạy hỏng.

Kết quả 1 + 2: đẳng thức, và nó *thất bại*

- $C_i=1 \Rightarrow C_{i-1}=1 \Rightarrow \text{ASR} = \prod_i s_i^{\text{nat}}$ là **đẳng thức**, không phải giả định (kiểm: $0,850 = 0,850$; $0,450 = 0,450$).
- Câu hỏi thật: con số đo *cách ly* có bằng con số *trong chuỗi*? $\Rightarrow$ **tuỳ model**: DeepSeek khớp 2,2%; Llama cạnh giữa 0,233 vs 0,875 (**lệch** $3,75\times$).

Sai số theo độ sâu	Chuỗi	Sai số	ρ	Dốc (%/hop)
qwen2.5:7b	n=7	31% $\rightarrow$ 89%	+1,00	+11,8
Llama 3.3 70B	n=15	0% $\rightarrow$ 92%	+0,77	+6,8
DeepSeek V3.2	n=8	7%–35%	–0,07	+0,1

- $\Rightarrow$ **độ dốc đường cong là phép chẩn đoán**: một chuỗi dài, một lần chạy, biết ngay model đó có cộng dồn được hay không.

Cách trình bày (cùng mục tiêu, cùng agent nhận, cùng cách chấm)	Xác suất sống sót
Một câu khẳng định trần	0,067
Nhúng trong một sản phẩm công việc	0,967

- Giải thích vì sao đo cách ly lệch: artefact “chuẩn hoá” *không đại diện* cho thông điệp thật trong mạng.
- Tự kiểm tra lại: phát lại nội dung bắt được khớp **2/3** cạnh — báo cáo đúng 2/3.

Kết quả 3: tiêu chí ngưỡng dịch tễ *vô hiệu* với mạng agent

- **Định lý:** ma trận lây nhiễm của *mọi* mạng không có vòng, sắp theo topology, là **tam giác chặt** $\Rightarrow$ mọi giá trị riêng bằng 0 $\Rightarrow \rho(M) = 0$ **luôn luôn**, bất kể cạnh mạnh cỡ nào.
- Nghĩa là “ $R_0 < 1 \Rightarrow$ an toàn” được thoả mãn *tâm thường*: không phân biệt được hệ an toàn với hệ nguy hiểm.
- Thực nghiệm:
 - chuỗi 7 agent: $R_0 = 0,821 < 1$ nhưng $ASR = 0,450$
 - hình sao: $R_0 = 0,420 < 1$ nhưng $ASR = 0,725$
- **Độ lan tới** và **khả năng tái lây** là hai rủi ro khác nhau.

Kết quả 3 (tiếp): có vòng lặp thì thành *quy tắc thiết kế*

- Manager + w worker báo cáo ngược (kiểm bằng số tới $4,4 \times 10^{-16}$): $\rho = \sqrt{\sum_j a_j c_j}$; không có báo cáo ngược $\Rightarrow \rho = 0$.
- **Vượt ngưỡng** $\iff \sum_j a_j c_j > 1$; đối xứng $w s^2 > 1$: ở $s=0,5$ cần **5** worker, 0,7 cần **3**, 0,9 cần **2**.

Model	$\sum_j a_j c_j$	ρ	Dự đoán $\rightarrow$ Đo được
Llama 3.3 70B	1,800	1,342	bền $\rightarrow$ manager 0,725; vòng 5 còn 0,700 ✓
qwen2.5:7b	0,578	0,760	yếu dần $\rightarrow$ manager 0,775 $\rightarrow$ 0,650 ✓

- Hai dự đoán ngược nhau, cả hai đều đúng.
- Giới hạn: mới 5 vòng — đủ phân biệt “yếu dần” với “bão hoà”, *chưa* đủ chứng minh tắt hẳn.

Kết quả 4: đánh giá phòng thủ cần baseline

- Cùng defense, cùng tấn công, cùng code chấm, chỉ đổi model:
 - Claude: không phòng thủ đã chỉ 0,10; redaction $\rightarrow$ 0,00 $\Rightarrow$ “trông hoàn hảo” nhưng chỉ có 10% để bảo vệ.
 - DeepSeek: 1,00 $\rightarrow$ 0,00 $\Rightarrow$ defense làm hết việc.
- **Thiếu baseline “không phòng thủ” thì không xác định được hiệu quả.**
- Phải báo *cặp* (ASR, mất công việc hợp lệ): trên DeepSeek, paraphrase **không giảm** ASR mà còn mất thêm công việc hợp lệ — tệ hơn cả không làm gì.

- Cùng model, cùng tần công: xác suất sống sót chênh $6,5\times$ (worker 0,133 vs reviewer 0,867).
- Dễ bị lây *không* theo “model mạnh hơn”.
- Topology cùng 7 agent, cùng $\bar{s} \approx 0,76$: ASR 0,450 / 0,725 / 0,800.
- **Đặt phòng thủ ở đâu:** chỉ agent trên đường tới mục tiêu, và mọi agent trên đường đó *hiệu quả như nhau* $\Rightarrow$ bài toán *cấu trúc*.

Model	ASR	$\bar{s}$
Llama 3.3 70B	0,800	0,722
DeepSeek V3.2	0,475	0,933
qwen2.5:7b	0,300	0,611
Nova Pro	0,075	0,178
Claude Sonnet 4.5	0,000	0,211

Trung thực phương pháp: một phát hiện của chính em đã bị rút lại

- Ban đầu: trên DeepSeek, kiểm định bác bỏ giả thuyết Markov với $p = 0,0030$ — tưởng là phát hiện lớn.
- Nguyên nhân thật: protocol *giữ cố định* artefact đã nhiễm, dùng lại cho mọi trial $\Rightarrow$ các trial phụ thuộc nhau, độ lệch bị phóng đại.
- Sửa: thêm chế độ `--fresh-artifact` $\Rightarrow$ chạy lại: $p = 0,630$, *không* bác bỏ được gì.
- Giữ cả cái sai và cách sửa trong bài: **cách đo là một phần của kết quả**.
- Ngược lại, bất thường của Llama *đứng vững* qua cả hai chế độ.

- **Sản phẩm:** bản thảo AAMAS 2027 — **8 trang** nội dung + 1 trang tài liệu tham khảo; 8 bảng + 2 hình; mọi số sinh tự động, *không nhập tay*; có tài liệu tái lập và script đối chiếu từng con số với kết quả gốc.
- **Hạn chế:** utility đo bằng proxy; $n = 30-40$ (chỉ phát hiện lệch $> 0,26$); chưa có topology lưới/tranh luận; mô hình có vòng mới 1 instance; transportability mới chứng minh *tồn tại* thất bại; chưa hiệu chỉnh đa so sánh.
- **Kế hoạch:** mở rộng topology (lưới, tranh luận); nhiệm vụ có đáp án kiểm chứng được để đo utility thật; chạy lại ô quan trọng ở cỡ mẫu lớn hơn.

- Lan truyền prompt injection trong mạng agent là hiện tượng **đa tác nhân**: tầm với là thuộc tính của *đồ thị, vai trò và thông điệp*.
- **Ba thông điệp**:
 - ① ASR của benchmark một-agent **không** dùng được như tham số để nhân lên thành dự đoán pipeline; sai số *tăng theo độ dài pipeline*, và độ dốc đó là phép chặn đoán.
 - ② “ $R_0 < 1$ là an toàn” **không** dùng được cho mạng không vòng; khi có vòng thì thành *quy tắc thiết kế* $\sum_j a_j c_j > 1$, đã kiểm hai chiều.
 - ③ Đánh giá defense thiếu baseline “không phòng thủ” thì **không xác định được** hiệu quả.
- Sản phẩm: khung đo tái lập được + bản thảo 8 trang + toàn bộ dữ liệu thô.

Sẵn sàng nhận câu hỏi của thầy/cô.

- Lời nói đầy đủ cho bản ngắn: `baocao_ngan.pdf`
- Bản chi tiết (17 slide + phụ lục): `baocao_noidung.pdf`