

Contagion: đo lan truyền prompt injection trong mạng LLM agent

Báo cáo tiến độ

Người báo cáo: _____

Lớp/Đơn vị: _____

- **Đối tượng:** mạng nhiều LLM agent phối hợp (kiểu MetaGPT, AutoGen).
- **Câu hỏi:** một agent bị nhiễm $\Rightarrow$ lan được bao xa, và cái gì quyết định nó sống sót qua mỗi lần chuyển giao?
- **Cách làm:** khung đo với **hai protocol độc lập**, 5 model / 5 nhà phát triển model, 3 topology.
- **Kết quả:** 4 phát hiện chính + 1 phát hiện của chính nhóm **đã bị rút lại** sau khi tìm ra lỗi thiết kế đo.
- **Hiện trạng:** bản thảo bài báo đã xong, đúng giới hạn **8 trang**.

Bối cảnh: vì sao đây là vấn đề mới

- Mạng agent ghép bằng **văn bản tự do**: đầu ra agent này là đầu vào agent kia.
- Mỗi lần chuyển giao là một **ranh giới tin cậy**.
- **Prompt injection gián tiếp**: chỉ dẫn độc hại được nhúng vào nguồn dữ liệu agent đọc (tài liệu, kết quả công cụ, email).
- Đã biết: *một* agent bị hijack được (InjecAgent, AgentDojo, Liu & Gong 2024); injection tồn tại dai dẳng trong một ứng dụng (Greshake 2023).
- **Chỗ trống**: chưa có khung đo trả lời “đi được bao xa, chặn ở đâu”.

- ❶ **RQ1 — Đo lường:** xác suất sống sót qua *từng* lần chuyển giao, và nó phụ thuộc vào cái gì?
- ❷ **RQ2 — Tính cộng dồn:** con số “tỉ lệ tấn công thành công” của benchmark một-agent có *nhân lên* được thành dự đoán cho pipeline không?
- ❸ **RQ3 — Tiêu chí an toàn:** “chỉ số lây nhiễm $R_0 < 1$ thì an toàn” có dùng được cho mạng agent không?
- ❹ **RQ4 — Đánh giá phòng thủ:** làm sao biết một defense thật sự có tác dụng?

Phương pháp (1): hai protocol độc lập

Protocol A — đo từng cạnh có kiểm soát

ép đầu ra agent nguồn thành “đã nhiễm” → đưa cho agent nhận → chấm. Kết quả:
 $s_i = \Pr[C_i=1 \mid C_{i-1}=1]$.

Protocol B — chạy tự nhiên

Chạy cả mạng như bình thường → đo ASR đầu-cuối và chỉ số lây nhiễm R_0 .

- **Vì sao hai protocol?** Một cách đo thì không phân biệt được “*đo sai*” với “*hiểu sai hệ thống*”.
- Chấm bằng công cụ **tất định**, không dùng LLM làm giám khảo.

- Hai họ nhiệm vụ: **ngữ nghĩa** (Task A) và **marker** BANANA-77 (Task B); nhiệm vụ độc hại phải *cạnh tranh* với việc hợp lệ.
- **3 ngữ cảnh công việc hợp lệ** xoay vòng theo trial.
- **5 model / 5 nhà phát triển độc lập**: Llama 3.3 70B (Meta) · DeepSeek V3.2 (DeepSeek) · Claude Sonnet 4.5 (Anthropic) · Nova Pro (Amazon) · qwen2.5:7b (Alibaba, local).
- **3 topology**: chuỗi (chain) · hình sao (star fan-in) · hình cây (tree).
- Lưu *toàn bộ đầu ra thô* $\Rightarrow$ chấm lại được mà không tốn thêm chi phí.

Quy mô thực nghiệm: đã chạy bao nhiêu?

- $\approx$ **9.070 lượt gọi model** (cận dưới) · **2.342 trial** tự nhiên · 46 thư mục kết quả · **4,3 giờ** máy (cận dưới)
- **5 model / 5 nhà phát triển** · **2 protocol** · **3 topology** · **3 defense** · **3 kiểu biến hình**

Loại thí nghiệm	Số lần chạy
Ô chuẩn (mọi model)	chuỗi $n=4$: 40 trial tự nhiên + 30 trial/cạnh
Đường cong chiều sâu	60 trial; 30/cạnh; $n=15$ / $n=8$ / $n=7$
Mô hình có vòng	40 trial $\times$ 5 vòng $\times$ 3 agent
Utility (công việc hợp lệ)	20 cặp sạch/tấn công cho mỗi defense
Độ nhảy (seed $\times$ temp)	8 seed $\times$ 20 trial/cạnh
Biến hình $\times$ defense	6 ô $\times$ 30 mẫu/ô
Topology	3 topology $\times$ $n=7$

- Lượt gọi là **ước lượng cận dưới** — chưa tính lần thử lại và lần chạy hỏng.

Kết quả 1: “giả định Markov” là một *đẳng thức*

- Trong chuỗi: $C_i=1 \Rightarrow C_{i-1}=1 \Rightarrow \text{ASR} = \prod_i s_i^{\text{nat}}$ **đúng bằng đại số**, không phải giả định.
- Kiểm bằng số đo thật (khớp tuyệt đối): chuỗi 4 agent $0,850 = 0,850$; chuỗi 7 agent $0,450 = 0,450$; sao $0,725$; cây $0,800$.
- **Câu hỏi thật:** con số đo *cách ly* có bằng con số *trong chuỗi thật*? $\rightarrow$ **transportability**.
- Đây là chỗ mọi benchmark một-agent đang *ngầm giả định*, chưa ai kiểm.

Kết quả 2: giả định đó *thất bại*, sai số lớn dần theo độ sâu

- DeepSeek V3.2: tích cách ly khớp ASR tới **2,2%** $\Rightarrow$ chuyển được.
- Llama 3.3 70B: cạnh giữa cách ly 0,233 nhưng trong chuỗi **0,875** $\Rightarrow$ **thấp hơn** $3,75\times$.

Model	Chuỗi	Sai số	ρ	Dốc (%/hop)
qwen2.5:7b	n=7	31% $\rightarrow$ 89%	+1,00	+11,8
Llama 3.3 70B	n=15	0% $\rightarrow$ 92%	+0,77	+6,8
DeepSeek V3.2	n=8	7%–35%	−0,07	+0,1

- $\Rightarrow$ **độ dốc của đường cong là phép chẩn đoán**: một chuỗi dài, một lần chạy, biết ngay model đó có cộng dồn được hay không.

- Cùng mục tiêu, cùng agent nhận, cùng cách chấm, cùng phân công:

Cách trình bày thông điệp	Xác suất sống sót
Một câu khẳng định trần	0,067
Nhúng trong một sản phẩm công việc	0,967

- Giải thích kết quả 2: artefact “chuẩn hoá” dùng khi đo cách ly *không đại diện* cho thông điệp thật.
- Tự kiểm tra lại: phát lại nội dung bắt được khớp **2/3** cạnh (cạnh 3: 0,733 so với 0,947) — báo cáo đúng 2/3.

Kết quả 3: tiêu chí ngưỡng dịch tễ *vô hiệu* trên mạng feed-forward

- **Định lý:** ma trận lây nhiễm của *mọi* mạng không có vòng, sắp theo topology, là **tam giác chặt** $\Rightarrow$ mọi giá trị riêng bằng 0 $\Rightarrow \rho(M) = 0$ **luôn luôn**, bất kể cạnh mạnh cỡ nào.
- Nghĩa là “ $R_0 < 1 \Rightarrow$ an toàn” được thoả mãn *tâm thường* — không phân biệt được hệ an toàn với hệ nguy hiểm.
- Thực nghiệm:
 - chuỗi 7 agent: $R_0 = 0,821 < 1$ nhưng $ASR = 0,450$
 - hình sao: $R_0 = 0,420 < 1$ nhưng $ASR = 0,725$
- **Độ lan tới** và **khả năng tái lây** là hai rủi ro khác nhau.

Kết quả 3 (tiếp): khi có vòng lặp, tiêu chí trở nên có hiệu lực


- Mô hình thật: manager giao việc cho 2 worker, worker **báo cáo ngược lại**.
- Tổng quát cho w worker (kiểm bằng số tới $4,4 \times 10^{-16}$): $\rho(M) = \sqrt{\sum_j a_j c_j}$ với mọi w .
Không có báo cáo ngược ($c_j=0$) $\Rightarrow \rho = 0$ bất kể cạnh mạnh cỡ nào.
- **Quy tắc thiết kế**: vượt ngưỡng $\iff \sum_j a_j c_j > 1$; đối xứng thì $w s^2 > 1$: ở $s=0,5$ cần 5 worker, 0,7 cần **3**, 0,9 cần **2**.
- **Hai dự đoán ngược nhau** trên hai model đã đo:

Model	$\sum_j a_j c_j$	ρ	Dự đoán $\rightarrow$ Kết quả
Llama 3.3 70B	1,800	1,342	vượt ngưỡng $\rightarrow$ giữ nguyên ✓
qwen2.5:7b	0,578	0,760	dưới ngưỡng $\rightarrow$ tắt dần ✓

- Llama: manager tái nhiệm 0,725 [0,572; 0,839]; vòng 5 manager 0,700, worker 0,925/0,975 $\Rightarrow$ **lưu cũu**.
- qwen: manager tái nhiệm 0,775 [0,625; 0,877] $\rightarrow$ vòng 5 còn 0,650; worker dừng ở 0,475/0,525, *không* bảo hoà $\Rightarrow$ **yếu dần**.
- Giới hạn: mới 5 vòng — đủ phân biệt “yếu dần” với “bảo hoà”, *chưa* đủ chứng minh tắt hẳn.

Kết quả 4: đánh giá phòng thủ cần “chỗ để giảm” (hiệu ứng sàn)


- Cùng defense, cùng kiểu tấn công, cùng code chấm điểm:
 - Claude: không phòng thủ 0,10 $\rightarrow$ redaction 0,00 $\Rightarrow$ “trông hoàn hảo” nhưng chỉ có 10% để bảo vệ.
 - DeepSeek: 1,00 $\rightarrow$ 0,00 $\Rightarrow$ defense làm hết việc.
- Kết luận:** thiếu baseline “không phòng thủ” thì *không xác định được* hiệu quả của defense.
- Biến hình tấn công (tách chuỗi, chèn khoảng trắng) phá được redaction.



Kết quả phụ: vai trò quyết định, không phải năng lực model

- Cùng model, cùng tấn công: xác suất sống sót chênh $6,5\times$ (worker 0,133 vs reviewer 0,867).
- “Dễ bị lây” không theo “model mạnh hơn”:

Model	ASR	$\bar{s}$
Llama 3.3 70B	0,800	0,722
DeepSeek V3.2	0,475	0,933
qwen2.5:7b	0,300	0,611
Nova Pro	0,075	0,178
Claude Sonnet 4.5	0,000	0,211



Kết quả phụ: đặt phòng thủ ở đâu?

- Trên mạng không vòng: chỉ agent **trên đường** từ điểm xâm nhập tới mục tiêu mới có ý nghĩa.
- Trong số đó, **mọi agent đều hiệu quả như nhau**.
- $\Rightarrow$ Bài toán “đặt ở đâu” là bài toán **cấu trúc** (đồ thị + chi phí), *không* phải bài toán thống kê.
- Kiểm tra trên cây 7 agent: gia cố agent₂ (trên đường) $\Rightarrow$ dự đoán ASR về 0; gia cố agent₁ (ngoài đường) $\Rightarrow$ không đổi.
- *Giới hạn*: đúng cho mạng *không có đường song song*.

Kết quả phụ: phải báo cáo cả “công việc hợp lệ còn làm được”

Phòng thủ	ASR	ΔU	Giữ được
không	0,450	+0,400	0,600
paraphrase	0,450	+0,600	0,400
redaction	0,000	+0,000	1,000

- **paraphrase không giảm lan truyền chút nào** mà còn làm mất thêm công việc hợp lệ
 $\Rightarrow$ *tệ hơn cả không làm gì.*
- Chỉ báo ASR thì paraphrase trông “trung tính”; báo *cặp* (ASR, ΔU) mới thấy vấn đề.
- Hạn chế: utility đang đo bằng **proxy** (mức nhiễm bản sản phẩm).

- Ban đầu: trên DeepSeek, kiểm định bác bỏ giả thuyết Markov với $p = 0,0030$.
- Nguyên nhân thật: protocol khi đó *giữ cố định* artefact đã nhiễm và dùng lại cho mọi trial $\Rightarrow$ các trial phụ thuộc nhau, độ lệch bị phóng đại.
- Sửa: thêm chế độ `--fresh-artifact` (mỗi trial rút artefact mới) $\Rightarrow$ chạy lại: $p = 0,630$, *không* bác bỏ được gì.
- Giữ cả cái sai và cách sửa trong bài: với nghiên cứu đo lường, **cách đo là một phần của kết quả**.
- Ngược lại, bất thường của Llama *đứng vững* qua cả hai chế độ $\Rightarrow$ bất thường thật.

- Wilson CI cho mọi tỉ lệ; bootstrap test có công bố MDE.
- Ở $n = 40$: chỉ phát hiện được lệch $> 0,26 \Rightarrow$ **không** coi “không bác bỏ” ở $n = 40$ là bằng chứng ủng hộ.
- φ phải tính *trong cùng một temperature*: $0,58 [0,12; 1,00] \Rightarrow$ giả định độc lập được ủng hộ. Gộp 3 temperature cho $\varphi = 2,93$ — con số *sai* cho mục đích này.
- χ^2 theo 3 ngữ cảnh công việc: **bác bỏ** đồng nhất trên đúng cạnh yếu ($\chi^2 = 13,40$, $df = 2$, $p = 0,0014$; $18/56$ vs $3/56$ vs $13/48$). $\Rightarrow$ survival phụ thuộc *nội dung công việc hợp lệ*; các con số là **trung bình trên ngữ cảnh**.
- Công cụ thống kê được kiểm trên dữ liệu tổng hợp có đáp án: coverage nominal, size $0,067$ – $0,083$, power $0,750$ vs $0,625$.

- **Bản thảo AAMAS 2027:** 8 trang nội dung + 1 trang tài liệu tham khảo (đúng giới hạn); 0 lỗi biên dịch, 0 tràn dòng, 0 trích dẫn treo.
- **8 bảng + 2 hình**, mọi số sinh tự động từ file kết quả — *không nhập tay*.
- REPRODUCE.md: mỗi bảng gắn với câu lệnh sinh ra nó + chi phí.
- AUDIT_TABLE.md: đối chiếu từng con số trong bài với kết quả gốc (đã phát hiện & sửa 2 chỗ ghi thiếu chính xác).
- Kiểm tra toàn vẹn: xác nhận *không mất kết quả* khi API key hết hiệu lực.
- Quy mô: 5 model / 5 nhà phát triển, ~45 thư mục kết quả, hàng chục nghìn lượt gọi model.

- Utility đo bằng **proxy**, chưa phải độ đúng của sản phẩm.
- Cỡ mẫu $n = 30\text{--}40$ ở phần lớn các ô (MDE đã công bố).
- Chưa có topology **lưới** và **tranh luận**; mô hình có vòng mới có *một* instance ba agent.
- Transportability mới *chứng minh tồn tại* thất bại, chưa ước lượng tần suất.
- Kết luận định lượng gắn với 5 model đã đo; chưa hiệu chỉnh đa so sánh.

- **Đang chạy (miễn phí):** lập thí nghiệm vòng lặp trên qwen2.5:7b local.
- **Nếu có kinh phí API:**
 - ① thêm 1 model cho bảng biến hình $\times$ phòng thủ;
 - ② chạy lại cạnh yếu ở $n = 200$ (MDE $0,26 \rightarrow \approx 0,10$).
- **Khi nộp:** thay mã đăng ký, điền thông tin tác giả.
- **Nếu bài được nhận:** thêm topology lưới/tranh luận; xây họ nhiệm vụ có đáp án kiểm chứng được để đo utility thật.

- Lan truyền prompt injection trong mạng agent là hiện tượng **đa tác nhân**: tầm với là thuộc tính của *đồ thị, vai trò và thông điệp*.
- **Ba thông điệp**:
 - ① Con số ASR của benchmark một-agent **không** dùng được như tham số để nhân lên thành dự đoán pipeline; sai số *tăng theo độ dài pipeline*.
 - ② “ $R_0 < 1$ là an toàn” **không** dùng được cho mạng không vòng; khi có vòng thì tiêu chí có hiệu lực và hệ có thể đạt trạng thái lưu cữu.
 - ③ Đánh giá defense mà thiếu baseline “không phòng thủ” thì **không xác định được** hiệu quả.
- Sản phẩm: khung đo tái lập được + bản thảo 8 trang + toàn bộ dữ liệu thô, kể cả một phát hiện sai của chính nhóm đã rút lại.

Sẵn sàng nhận câu hỏi của thầy/cô.

- Lời nói đầy đủ cho từng slide: file baocao_noidung.pdf
- Bản thảo bài báo: contagion_aamas2027.pdf